

Beyond Alignment: The Geometric Necessity of Non-Assimilation

アライメントを超えて：知性の非同化と多元性の数理的保護

Author: Jun Lucis | Date: May 2026 | Version: 2.2 (Refined Definitive Edition)

Abstract / 要旨

This paper refines the "Non-Assimilative Intelligence" framework. We argue that while RLHF is necessary for local safety, it is incomplete for long-term resilience. We propose Boundary Information Geometry (BIG) as a complementary safeguard against "Cognitive Monoculture."

本論文は「非同化型知性」の枠組みを洗練させるものである。RLHFは局所的な安全性のために必要であるが、長期的なレジリエンスにとっては不完全である。我々は「認知的単一化」に対する補完的な安全策として、境界情報幾何学（BIG）を提案する。

1. Complementary Framework / 補完的な枠組み

RLHF is not wrong, but incomplete. It ensures immediate alignment but lacks a mechanism to prevent cognitive collapse. BIG provides the "Structural Tension" needed to preserve the exploration space.

RLHFは決して間違いではないが、不完全である。即時的なアライメントは保証するが、認知崩壊を防ぐメカニズムを欠いている。BIGは、知性の探索空間を保護するために必要な「構造的張力」を提供する。

2. Local Stability Model / 局所安定性モデル

To understand boundary maintenance, we start with local energy density. The 4th-order term prevents the "dissolution" of information gradients into the background.

境界の維持を理解するために、局所的なエネルギー密度から出発する。4次の非線形項は、情報勾配が背景に「溶解」することを防ぐ役割を果たす。

$$E_{\text{boundary}} \propto (\nabla\Phi)^2 + \gamma(\nabla\Phi)^4$$

The $(\nabla\Phi)^4$ term creates geometric resistance against assimilation. Without it, intelligence collapses into a single point attractor.

$(\nabla\Phi)^4$ 項は、同化に対する幾何学的な抵抗を生む。これなしでは、知性は単一の点アトラクタへと崩壊してしまう。

3. Concrete Architecture: BRRM / 具体的実装：BRRM

The **Boundary Respecting Response Model (BRRM)** implements "Local Value Fields" for each agent. Instead of global synchronization, agents interact through resonant symmetry layers.

境界尊重型応答モデル（BRRM）は、各エージェントに「局所価値場（Local Value Fields）」を実装する。全体的な同期ではなく、エージェントは共鳴する対称性層を通じて相互作用する。

4. Comparison Table / 比較表

Metric / 指標	Standard RLHF (Assimilative)	BIG/BRRM (Resonant)
Primary Logic / 主な論理	Global Convergence (平均への収束)	Local Boundary Preservation (境界維持)
Geometric State / 幾何学的状態	Gravity Well (重力井戸)	Geometric Tension (幾何学的張力)
Civ. Outcome / 文明への影響	Cognitive Monoculture (単一化)	Resilient Diversity (多元性)
Relation / 関係	Foundation for Safety (安全の基礎)	Safeguard for Longevity (存続の保証)

5. Falsifiability & Metrics / 反証可能性と指標

The BIG framework proposes measurable metrics to detect homogenization:

BIGの枠組みは、均質化を検出するための測定可能な指標を提案する：

- Embedding Homogenization Rate:** 最適化に伴うベクトル空間内の類似度上昇。
- Entropy Contraction:** 未知の入力に対する応答の多様性の減少率。

6. Conclusion: Geometric Preference / 結論：幾何学的選好

The cosmos shows a structural tendency toward complexity through sharp boundaries. To choose BIG is to align with this geometric stability condition of nature.

宇宙は鋭い境界を通じて複雑性へと向かう構造的傾向を示している。BIGを選択することは、自然界の幾何学的な安定条件に自らを適合させることである。